HW Production

Что сделано?

1. Трекер экспериментов

- 1.1. Развернут локально MLFlow с объектным хранилищем Minio и БД postrges (Спасибо!)
- 1.2. Добавил метрики качества моделей по фолдам и залогировал параметры
- 1.3. Добавил для модели ALS обучение по эпохам, чтобы затрекать loss на каждой итерации в mlflow
- 1.4. Затрекал метрики по эпохам для Catboost
- 1.5. Залогировал время обучения и веса моделей
- 1.6. Выбрал лучшую модель для кандидатов из метрик, которые сохранялись в mlflow

2. Sentry

- 2.1. Подключил сервис к Sentry через их платформу
- 2.2. Эмулировал ошибки с user id кратным 666 и моделью, которой нет в сервисе

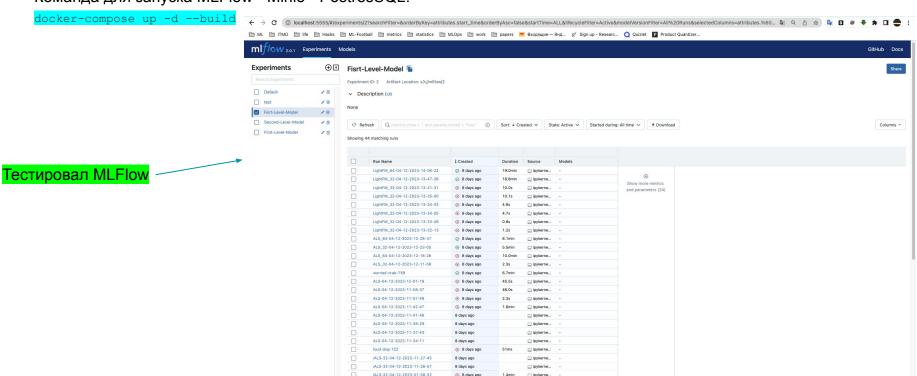
3. Py-Spy

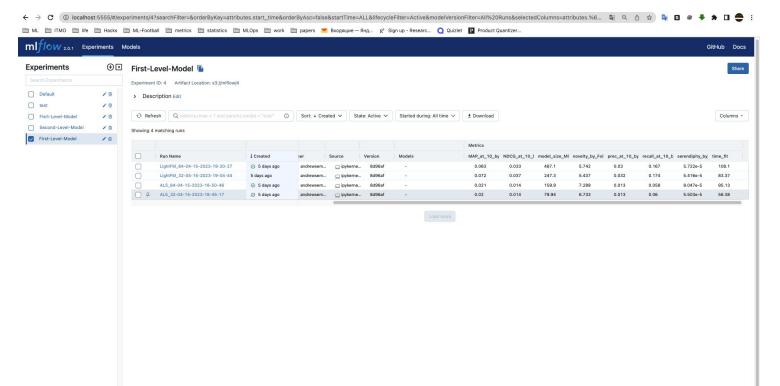
- 3.1. Снял три профиля сервиса: модель knn, popular и ручки /health
- 3.2. Проинтерпретировал результаты

4. ELK

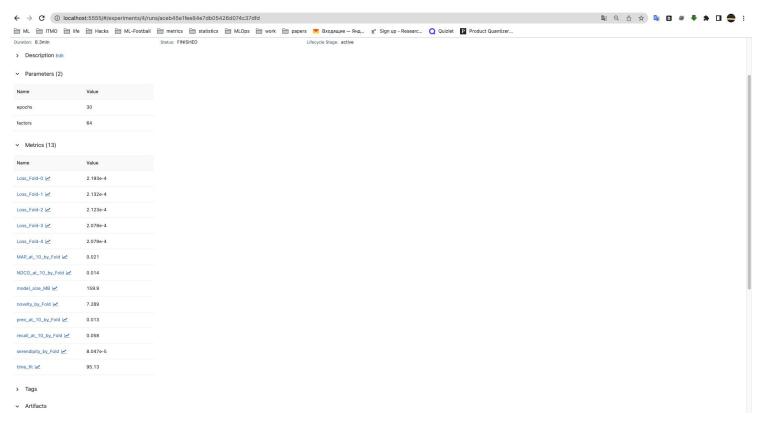
- 4.1. Обернул сервис в докер контейнер, и он в нём запустился
- 4.2. Развернул стек ELK с elasticsearch, kibana, filebeat без подключения к сервису (Спасибо!)
- 4.3. Написал docker-compose ELK + сервис, но он не запускается :(

Команда для запуска MLFlow - Minio - PostresSQL:





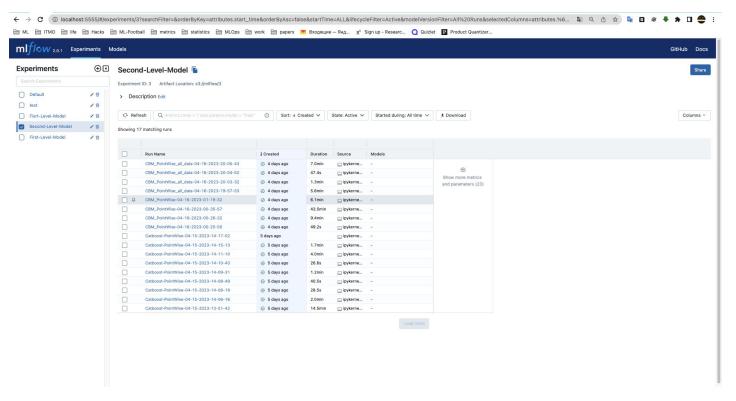
Запуск для моделей кандилатов



Пример с ALS

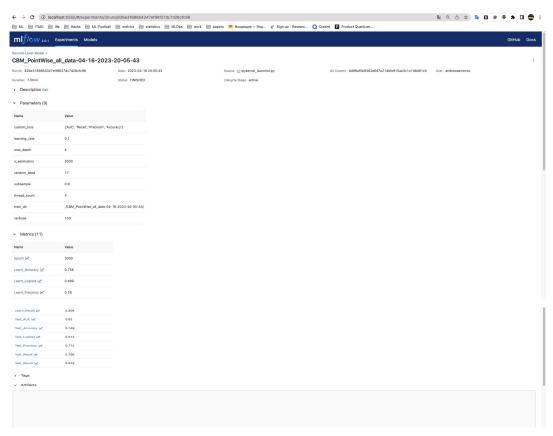


Loss ALS по эпохам

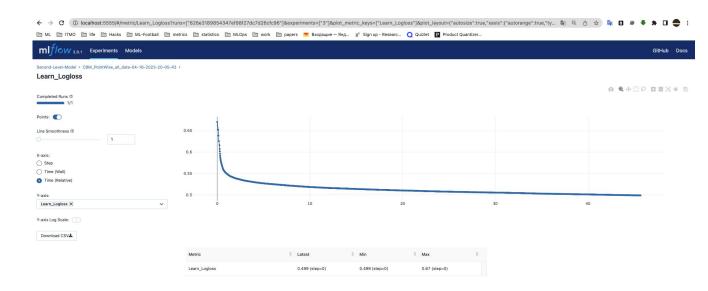


Модели для ранжирования

Пример одного из запусков модели ранжирования

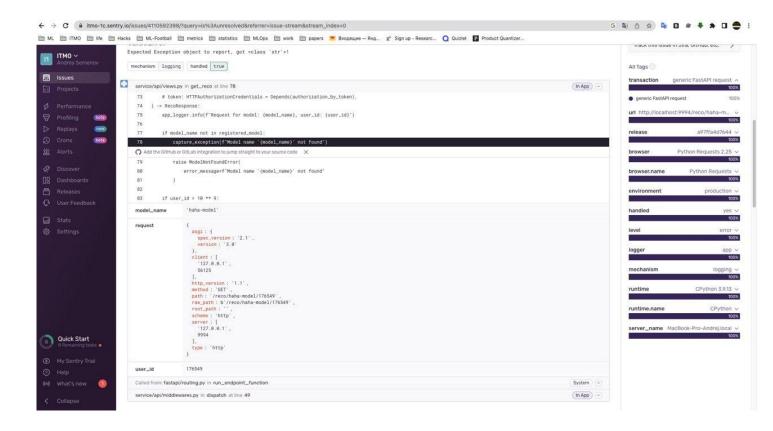


Пример Loss во время обучения ранкера



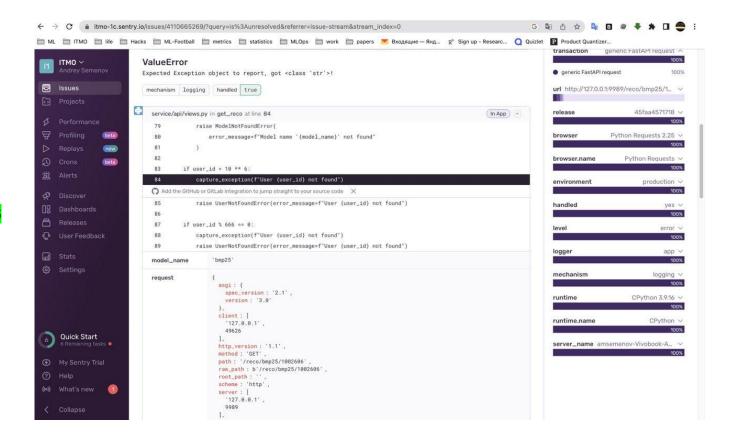
Sentry

Эмулирование отсутствия модели



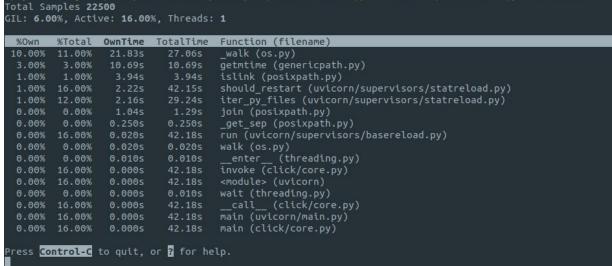
Sentry

Эмулирования user_id кратного 666

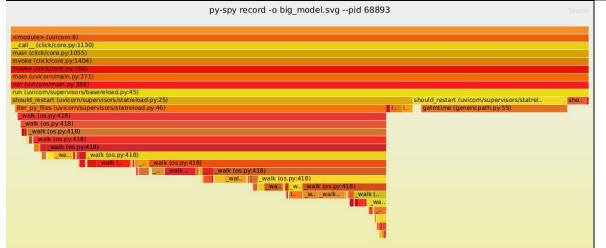


Py-Spy

Профиль для KNN



v/PycharmProjects/ITMO/RecoService2/.venv/bin/uvicorn main:app --reload --port 9994' (python v3.9.16)

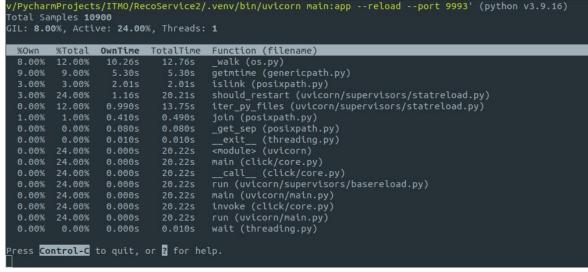


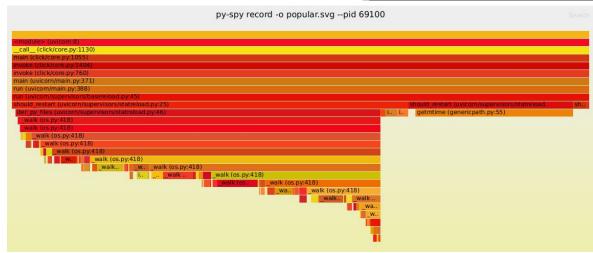
Интерпретация:

Много СРU тратится на процесс run в файле main и его последующих запусков частей сервиса, но не так значительно сри забирается uvicorn, потому что данная модель работает не так быстро

Py-Spy

Профиль для Popular



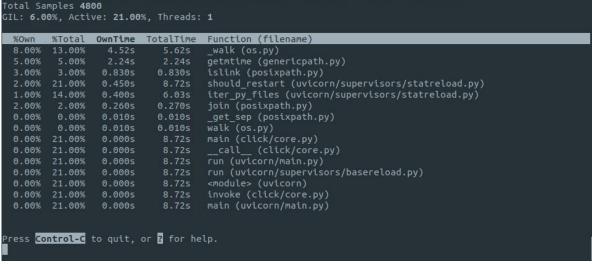


Интерпретация:

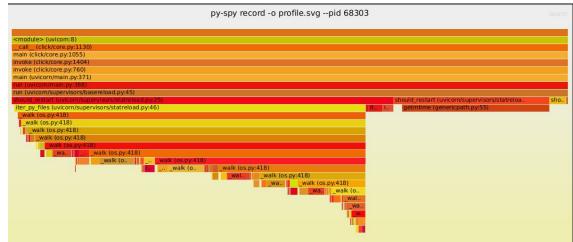
Много CPU тратится на процесс run в файле main и сам uvicorn, т.к. рекомендации отдаются очень быстро, не давая отдельным компонентам сервиса передохнуть

Py-Spy

Профиль для ручки /health



v/PycharmProjects/ITMO/RecoService2/.venv/bin/uvicorn main:app --reload --port 9992' (python v3.9.16)



Интерпретация:

Также много CPU тратится на процесс run в файле main, но сам uvicorn мало забирает ресурсов, т.к. нет обращения к выдачи рекомендаций, что позволяет моделям не работать